

RADAR URBANO

RADAR URBANO · 07-MAPA-MUNDI

1. ARQUITETURA

Camadas:

1. Interfaces: Perfil da Empresa no Google (Busca e Maps), Places API (New), WhatsApp do dono (número da casa), Dashboard Radar. Nenhuma outra.
2. Conectores: GBP, Places, WA, TTS; ao lado, Render & Delivery (cards, mapa, PDFs, QR, dashboard, envio com status). Conector executa, registra custo, devolve JSON; nunca decide.
3. Agentes, orquestrador e Guardião: Cartógrafo, Editor, Anfitrião, Tesoureiro, Redator-chefe. Cloud Scheduler → Pub/Sub → Cloud Run Jobs; Cloud Tasks por tenant. Guardião: humano com painel.
4. Cérebros: Gemini na Vertex AI (obrigatório para dado, medição, áudio, foto e decisão que toca o Google); linguagem intercambiável atrás do `LLMGateway`; Cloud TTS. Nenhum agente chama modelo direto.
5. Memória e prova: Firestore (estado por tenant), BigQuery (métricas, medições, Diário, custo, zonas), Cloud Storage (fotos, prints, PDFs, áudios), Secret Manager (nunca senha de cliente).

Regras:

1. Camadas estritas: cada camada fala só com a de baixo; trocar modelo, voz ou template não toca agente; trocar endpoint toca só o conector.
2. Gemini é o cérebro de dados e de Google: extração, aferição, classificação e toda decisão sobre API ou superfície do Google, com saída estruturada.
3. Um cliente é um tenant com zona: todo dado carrega `tenant_id`; o tenant só nasce se `zone.check` confirmar vaga (máximo 2 por segmento por zona, em transação).
4. Tudo é job idempotente: chave `tenant_id + agente + entrega + período`, verificada antes da ação externa.

5. Humano aprova, IA executa: P0 tudo antes; P1 lote (meta > 85% sem edição); P2 direto com QA de 10%; categoria principal, nome, endereço e notas 1 e 2 sempre com dois olhos.
6. Diário de Bordo é a verdade: toda ação externa grava linha imutável em `actions_log` com print; sem linha, não aconteceu.
7. Custo por cliente é métrica de primeira classe: alerta em R\$ 25/cliente/mês. Sem tempo real: dados do Google com data de referência; a máquina não fala com cliente final.

2. CÉREBROS

FUNÇÃO	MODELO	COMO
Extração e normalização (perfil, métricas, avaliações, perguntas, palavras-chave)	Gemini Flash (volume) · Pro (análise mensal)	<code>generateContent</code> + <code>responseSchema</code>
Aferição de posição e leitura de superfícies Google	Gemini + Grounding com Google Maps	Medição é <code>places.search_text</code> ; o Gemini interpreta e propõe termos
Decisões que tocam API do Google	Gemini Pro	Function calling com ferramentas do GBP
Transcrição dos áudios do Dia 0	Gemini multimodal	OGG + <code>responseSchema</code> : termos, raio, tom, limites, nome
Classificar avaliações e perguntas	Gemini Flash	Polling 30 min; lote noturno; cache de contexto
Julgar fotos	Gemini multimodal	<code>vision.assess_photo</code> ; nunca gera foto
Posts, respostas, roteiros, três frases	Linguagem (Claude Sonnet ou Gemini Pro)	<code>LLMGateway.generate</code> ; avaliação cega mensal
Verificação cruzada de números	Gemini Flash	<code>CROSSCHECK</code> → <code>{ok, numeros_fora[]}</code> ; bloqueia a síntese
Voz do Boletim	Cloud TTS Chirp 3 HD pt-BR	<code>TTS_VOICE_ID</code> fixo
Ordenar a fila do Guardião	Gemini Flash	Agrupar e ordenar; não aprova

LLMGateway

```
generate(task, tenant, input, schema?) -> Output
policy(task) -> {primary, fallback[], max_cost}
Gemini obrigatório, sem fallback (fora do ar = espera na fila):
  EXTRACT, MEASURE, CLASSIFY, GOOGLE_DECISION, AUDIO_IN, VISION, CROSSCHECK
linguagem (LLM_LANGUAGE_PRIMARY / LLM_LANGUAGE_FALLBACK):
  POST, REPLY_REVIEW, REPLY_QUESTION, BOLETIM, THREE_SENTENCES
anonimiza antes da chamada (dono, avaliador -> ids internos), salvo tarefa que exige
telemetria: tokens, custo, latência, prompt_versao, tenant -> llm_calls
```

Regras: (1) saída estruturada sempre; sem JSON válido, retry com temperatura menor e, na terceira falha, exceção no Guardiã; (2) prompts versionados no repositório, versão em `actions_log` e `llm_calls`; (3) avaliação cega mensal: 100 amostras por agente, dois humanos, sem saber o modelo; (4) cache de contexto renovado a cada 24 h; (5) nenhum dado pessoal no prompt sem necessidade; o modelo nunca vê número da casa nem token.

3. CONECTORES

Termos comuns ao Google: nome real sem termo de busca; categoria descreve o negócio; horários e fotos reais; avaliações sem incentivo, seleção ou dado do avaliador; suspeita denunciada pelo fluxo oficial; sem raspagem.

GBP

APIS	BUSINESS INFORMATION V1: ACCOUNTS.LOCATIONS.LIST , LOCATIONS.GET , LOCATIONS.PATCH (UPDATEMASK , VALIDATEONLY), ATRIBUTOS, CATEGORIES.LIST ; CAMPOS REGULARHOURS , SPECIALHOURS , PROFILE.DESCRPTION , SERVICEITEMS , METADATA.NEWREVIEWURI , METADATA.MAPSURI · PERFORMANCE V1: FETCHMULTIDAILYMETRICSTIMESERIES (CALL_CLICKS , BUSINESS_DIRECTION_REQUESTS , WEBSITE_CLICKS , BUSINESS_CONVERSATIONS , BUSINESS_IMPRESSIONS_{DESKTOP,MOBILE}_{SEARCH,MAPS}), SEARCHKEYWORDS/IMPRESSIONS/MONTHLY · V4: REVIEWS.LIST/REPLY , LOCALPOSTS.CREATE , MEDIA.CREATE · Q&A: QUESTIONS.LIST , ANSWERS.UPSERT · LOCATIONS.ADMINS.LIST · GETVOICEOFMERCHANTSTATE
Acesso	Formulário oficial das Business Profile APIs (1–2 semanas; dia 1 da semana 1). OAuth 2.0 com a conta operacional (2FA), Gerente em cada perfil, escopo <code>business.manage</code> ; <code>GBP_OPERATOR_REFRESH_TOKEN</code> ; <code>tenant-{id}-gbp-oauth</code> aponta por padrão para o token da casa
Cotas	Baixas para edição; pedir aumento com o acesso. Desempenho em lote 03h (D-3..D-1); edições por Cloud Tasks, uma por tenant, retry em 429/5xx; polling 30 min, <code>pageSize</code> 50. Palavras-chave abaixo do limiar chegam como faixa
Armadilhas	Categoria principal só com humano; <code>patch</code> sem <code>updateMask</code> apaga o resto (conector recusa); <code>SUSPENDED</code> / <code>PENDING_VERIFICATION</code> abre incidente; <code>hasGoogleUpdated</code> = revisar antes de sobrescrever; nota chega como enum <code>ONE..FIVE</code> ; foto e post exigem URL assinada curta; v4 pode migrar; descrição ≤ 750 caracteres

Places

ENDPOINTS	PLACES:SEARCHTEXT COM TEXTQUERY , LOCATIONBIAS CIRCULAR NO PONTO (RAIO = PASSO), RANKPREFERENCE PADRÃO, LANGUAGECODE=PT-BR , REGIONCODE=BR , PAGESIZE=20 , MÁSCARA PLACES.ID · PLACES/{PLACE_ID} SÓ NO DIA 0
Acesso e cotas	Chave restrita à API e ao IP de saída (Cloud NAT); PLACES_API_KEY ; nunca no navegador. Uma chamada por termo por ponto; grade 3×3 a 5×5; ≤ 25 termos; ≈ 240 chamadas/tenant/mês; teto em limites_json ; R\$ 3–8
Termos	Nada além de 30 dias exceto place_id : guardamos só place_id do cliente, data, termo, ponto, lat/lng, posição
Método	Centro no endereço; passo = raio (3×3) ou raio ÷ 2 (5×5); posição = índice do place_id (1–20) ou "não encontrado". Verde top 3, cinza 4º–10º, vermelho fora do top 10. Mesmo horário sempre. Validação mensal: 20 buscas manuais, ≥ 85% no top 3, em qa_samples
Armadilhas	locationBias é viés, não cerca; rankPreference=DISTANCE mede outra coisa; sem languageCode / regionCode a lista muda; não pagnar além de 20; place_id pode mudar em fusão (reconfirmar por metadata.mapsUri); alerta de orçamento

WA (número da casa)

ENDPOINTS	POST /{PHONE_NUMBER_ID}/MESSAGES (TEMPLATE , AUDIO , IMAGE , DOCUMENT , INTERACTIVE) · POST /{PHONE_NUMBER_ID}/MEDIA · GET /{MEDIA_ID} · WEBHOOKS MESSAGES E STATUSES · /{WABA_ID}/MESSAGE_TEMPLATES · /{WABA_ID}/PHONE_NUMBERS (QUALITY_RATING)
Acesso	Portfólio do Radar Urbano verificado (dia 1); app com WhatsApp; número dedicado "Radar Urbano"; usuário de sistema → META_SYSTEM_USER_TOKEN ; META_APP_ID/SECRET ; WA_WEBHOOK_VERIFY_TOKEN ; DELIVERY_SENDER_PHONE_ID . Sem Tech Provider, sem Embedded Signup, sem conta do cliente
Modelos (Utilidade; rodapé "Responda SAIR para parar")	boletim_segunda : cabeçalho de vídeo (card + voz em MP4), números e data de referência, botão do dashboard; só com a janela de 24 h fechada · entrega_radar : cabeçalho de imagem · entrega_radar_pdf : cabeçalho de documento (nome lógico entrega_radar no código) · pergunta_sim_nao : botões · aviso_radar : {{1}} nome, {{2}} linha
Janela e horários	Livre só na janela de 24 h aberta pelo dono (botão conta). Dia 0: o dono abre pelo link da página do contrato; sem mensagem em 1 h, sai pergunta_sim_nao ("Podemos começar?"). Segunda: janela aberta → PNG + OGG livres; fechada → boletim_segunda . ≈ 25 mensagens/dono/mês. Boletim 7h; dia 1 e Dia 7 até 8h; aviso_radar e perguntas 8h–19h. R\$ 1–2
Armadilhas	Modelo com cara de marketing = rejeição; quality_rating cai com bloqueios (SAIR honrado na hora em wa_optout); nunca celular de alguém; audio/ogg Opus, PNG ≤ 5 MB, MP4 ≤ 16 MB; número do dono só como hash; texto livre vai a humano; token rotacionado a cada 90 dias

TTS + Render & Delivery

TTS	CHIRP 3 HD PT-BR, <code>TTS_VOICE_ID</code> FIXO; <code>OGG_OPUS</code> 48 KHZ; ≤ 60 S (CORTE POR ≤ 150 PALAVRAS; CONECTOR MEDE E RECUSA); NÚMEROS POR EXTENSO; CARD + OGG VIRAM MP4 PARA O MODELO
Render	HTML → PNG/PDF (Chrome headless), templates versionados; Mapa em SVG de <code>rank_measurements</code> ; PDFs de uma página em <code>radar-{amb}-artefatos/{tenant_id}/{entrega}/{periodo}.pdf</code> , URL assinada 30 dias, cópia no dashboard; QR: <code>gbp.get_review_link</code> → <code>render.qr</code> → PDF de balcão e comanda, sem prêmio; todo card traz cliente, período, data de referência
Dashboard	Next.js no Cloud Run; link fixo <code>DASHBOARD_BASE_URL/t/{token}</code> ; senha opcional criada pelo cliente (Identity Platform; link mágico = sem senha; link único = criar/redefinir); visões de hora em hora; números, Mapa, Diário com prints, Voz do Cliente, Reputação, arquivos, Horas, custo por contato; abertura grava <code>lido_em</code>
Delivery	Recebe (tenant, entrega, período, artefatos); decide janela × modelo; sobe mídia; envia; grava <code>enviado_em</code> , <code>entregue_em</code> , <code>lido_em</code> ; chave <code>tenant + entrega + período</code> ; reenvio único após 2 h, depois incidente; respeita <code>wa_optout</code> e horários; fila <code>deliveries.send</code>

4. FUNDAÇÃO

PEÇA	ESCOLHA
Projetos e APIs	<code>radar-hml</code> , <code>radar-prd</code> , <code>southamerica-east1</code> . Vertex AI, Places API (New), Business Profile APIs, Cloud TTS, Cloud Run, Cloud Build, BigQuery, Firestore, Secret Manager, Scheduler, Pub/Sub, Identity Toolkit. Sem Google Ads API
Execução	Cloud Run (webhooks, dashboard, painel, render); Cloud Run Jobs (um container por agente); ADK em Python; opção Agent Engine. Scheduler → Pub/Sub → Jobs; Cloud Tasks por tenant
Dados	Firestore (documento por tenant); BigQuery particionado por data, clusterizado por <code>tenant_id</code> ; Cloud Storage (bucket por ambiente, prefixo por tenant); tabela de feriados nacionais e municipais lida por <code>calendar.holidays</code>
Segredos, identidade, observabilidade	Secret Manager (um por uso); Identity Platform (cliente; painel com 2FA); Logging, Error Reporting, Monitoring; <code>llm_calls</code>
Código	GitHub → Cloud Build → Cloud Run; Terraform; prompts e templates versionados

```

tenants(tenant_id, nome, segmento, zona, tom_json, limites_json, termos[], raio_m, dono_nome, dono_wa_hash, criado_em)
zones(segmento, zona, cidade, tenants_ativos, limite=2)
locations(tenant_id, gbp_location_id, place_id, categoria, endereco, telefone, status)
metrics_daily(tenant_id, data, call_clicks, directions, website_clicks, conversations, impressions_search, impressions_maps, data_referencia, coletado_em)
keywords_monthly(tenant_id, mes, termo, impressoes)
rank_measurements(tenant_id, data, termo, grid_point, lat, lng, posicao)
reviews(tenant_id, review_id, data, nota, texto_hash, temas[], sentimento, respondida_em, resposta_id)
questions(tenant_id, question_id, data, texto_hash, respondida_em, resposta_id)
posts(tenant_id, post_id, data, tipo, foto_uri, texto, aprovado_por, publicado_em)
profile_audits(tenant_id, data, campo, antes, depois, origem)
actions_log(tenant_id, ts, agente, entrega, acao, alvo, entrada_uri, saida_uri, print_uri, prompt-versao, modelo, custo) -- Diário de Bordo, append-only
deliveries(tenant_id, entrega, periodo, artefato_uri, canal, enviado_em, entregue_em, lido_em)
llm_calls(tenant_id, ts, agente, task, modelo, tokens_in, tokens_out, custo, latencia_ms, prompt-versao)
hours_equivalence(acao, minutos)
qa_samples(tenant_id, data, action_id, veredito, nota_operador)

```

Contatos = `call_clicks + directions + website_clicks + conversations` ;

impressões e palavras-chave são contexto. `posicao` nula = não encontrado.

`profile_audits` com `origem='diagnostico'` é o "antes" do Dia 7.

Tenancy: (1) documento `tenants/{id}` com configuração, `limites_json`, tom, termos, raio, segmento, zona, estado, consentimento, subcoleções `approvals` e `queue` ; nasce só após `zone.check` ; (2) segredos por tenant (`tenant-{id}-gbp-oauth`), segredos da casa lidos só pelo conector dono, rotação 90 dias; (3) contas de serviço mínimas (só WA lê token da Meta; só Delivery lê o número claro; ninguém tem `UPDATE / DELETE` em `actions_log`); (4) `dono_wa_hash` com sal por tenant; textos de terceiros só como hash, temas e sentimento.

Estados: `zone.check` (antes de existir) → `created` → `billing_active` → `profiled` → `gbp_linked` OU `gbp_pending_verification` → `live` .

5. AGENTES

Todos em ADK; nenhum chama API direto; nenhum fala com o dono senão via `delivery.send`; todos usam `diario.log` e `guardiao.submit`. Sentinela de calendário é rotina do Editor. Convite de avaliação não existe. Entradas de cada agente: as tabelas da seção 4 que ele lê, mais `tom_json`, `limites_json` e fatos da casa do Dia 0.

Cartógrafo

GATILHO	DIA 0 APÓS <code>GBP_LINKED</code> , DIA 7 E SÁBADO 03H (REDUZIDA: 3×3, ATÉ 5 TERMOS); DIA 1 02H (COMPLETA)
Ferramentas / cérebro	<code>places.search_text</code> · <code>gbp.get_keywords</code> · <code>gbp.get_location</code> · <code>render.map_svg</code> · <code>render.card</code> · <code>cost.per_tenant</code> . Gemini Pro + Grounding com Google Maps; Flash normaliza; sem linguagem
Saídas / guardrails	<code>rank_measurements</code> ; Mapa; JSON do Diagnóstico; <code>editor.tasks</code> ; categoria ao Guardião. ≤ 25 termos; grade ≤ 5×5; teto em <code>limites_json</code> ; só o <code>place_id</code> do cliente; nunca cita outro perfil; mede mesmo com perfil pendente
Métricas / teste	Custo de medição; cobertura da grade; variação de verdes. Teste: ≥ 85% no top 3 vs 20 buscas manuais; reduzida < 2 min; nenhum <code>place_id</code> de terceiros

Cartógrafo. Verde = top 3, cinza = 4–10, vermelho = fora do top 10 ou não encontrado. Sem termos sem impressões, sem citar outro perfil, sem termos no nome, sem promessa de posição.
JSON: {territorio:[{termo,pontos_verde,pontos_cinza,pontos_vermelho,variacao_mes}], diagnostico:{termos_no_top3,termos_fora,maior_lacuna}, oportunidades:[{termo,motivo,acao_sugerida}], auditoria_perfil:[{campo,atual,sugerido,impacto}], nap_consistente:bool}

Editor

GATILHO	SEGUNDA 04H (POST); DIÁRIO 05H (FERIADOS 72 H ANTES); EDITOR.TASKS ; DIA 0 (AUDITORIA); DIA 7 (DIFF); DIA 1 (AUDITORIA MENSAL); APPROVALS.DECIDED
Ferramentas / cérebro	gbp.get_location · gbp.create_post · gbp.upload_media · gbp.patch_location · gbp.update_hours · gbp.update_services · calendar.holidays · vision.assess_photo · render.card · delivery.send . Linguagem (texto); Gemini (fotos e qualquer campo do perfil)
Saídas / guardrails	Guardião (P0/P1) ou publicação (P2), com print; posts ; profile_audits ; horários de feriado; auditoria de completude; diff do Dia 7; aviso_radar . Só fotos com assess_photo.ok ; categoria principal, nome, endereço via Guardião; ≤ 1 post/dia; descrição ≤ 750 caracteres; serviços sem preço; feriado sem padrão vira pergunta_sim_nao (sem resposta até 24 h antes, horário normal fica); nada publica em perfil suspenso ou pendente
Métricas / teste	Aprovação sem edição (> 85% no P1); feriados com ≥ 72 h (100%); completude. Teste: uma semana gera 1 post aprovado; feriado de teste vira horário + post 72 h antes com aviso; 100% com print; nenhum campo sensível sem aprovação

Editor da {casa}, tom {tom}. Nunca prometa resultado, posição ou desconto; nunca termos de busca no nome; só {fatos_da_casa} e {limites}. Post ≤ 300 caracteres com foto entre as disponíveis (nunca gerar). Feriado a 72 h: horário pelo padrão da casa e post ≤ 200 caracteres.
JSON: {post, foto_uri, justificativa, horario_feriado, publicar_em, requer_guardiao:bool}

Anfitrião

GATILHO	POLLING 30 MIN (→ GBP.REVIEW.NEW , GBP.QUESTION.NEW); LOTE NOTURNO; DIA 1 (REPUTAÇÃO, VOZ DO CLIENTE); PRIMEIRA SEMANA (QR); APPROVALS.DECIDED
Ferramentas / cérebro	gbp.list_reviews · gbp.reply_review · gbp.list_questions · gbp.answer_question · gbp.get_review_link · render.qr · render.pdf · render.card · classify.review . Gemini Flash (classificar); linguagem (responder); Gemini (violação de política)
Saídas / guardrails	Respostas no Google; reviews , questions ; Boletim de Reputação; classificação do mês; sinal de suspeita; QR em PDF. Nunca mensagem a cliente final; link oficial sem encurtador próprio; responde todas; notas 1 e 2 via Guardião em qualquer patamar; nunca dado do avaliador, compensação ou pedido de nota; texto só como hash; dúvida = exige_humano ; chave por review_id
Métricas / teste	Mediana < 2 h e 100% em 24 h; perguntas < 4 h; edição pelo Guardião; sinalizadas/mês. Teste: avaliação de teste respondida em < 2 h; "vocês têm estacionamento?" em < 4 h com dado do perfil; QR abre a tela oficial; nenhuma mensagem a outro número

Responde avaliações e perguntas públicas em nome da {casa}. Sem chavão; ao ponto; nunca compensação, dado do avaliador, discussão ou pedido de nota. Nota ≤ 3: desculpa, explicação, convite a falar com {responsavel} pelo {canal}. Pergunta: só perfil ou {fatos_da_casa}; sem certeza, exige_humano. ≤ 400 caracteres.
JSON: {resposta, tom_detectado, temas[], sentimento, suspeita_de_violacao:bool, exige_humano:bool}

Tesoureiro

GATILHO	HOURLY (VISÕES); DIÁRIO 03H (COLETA D-3..D-1); DIA 1 05H (EXTRATO, HORAS, CUSTO, JSON DO MÊS); SEGUNDA 06H (JSON DA SEMANA); COST.ALERT
Ferramentas / cérebro	gbp.get_daily_metrics · gbp.get_keywords · render.pdf · render.card · cost.per_tenant . Gemini Flash (normalizar); Pro só para três frases; números só de SQL
Saídas / guardrails	Visões do dashboard; metrics_daily ; Extrato (PDF); Horas Devolvidas (card); custo por tenant e alerta; JSONs para o Redator-chefe. Nenhum número de modelo; reconciliação < 2%; sempre data_referencia ; contato = 4 métricas; custo por contato = R\$ 499 ÷ contatos; nenhum campo de conversão, receita ou "novos clientes"; coleta por (tenant, data) substitui, nunca soma
Métricas / teste	Frescor (próprio < 1 h; Google ≤ D-3); reconciliação; custo vs R\$ 25. Teste: extrato sintético bate 100%; padaria (118 + 97 + 31 + 14) = 260 contatos e R\$ 1,92; nenhuma visão sem data_referencia

Três frases sobre este extrato, sem número fora do JSON, sem conversão, receita ou "novos clientes". Toques em Ligar = "ligações pelo perfil". Destaque a maior variação e o custo por contato. Diga até que data vão os dados.

Redator-chefe

GATILHO	DIA 0 (TRÊS FRASES); SEGUNDA 06H (BOLETIM; ENVIO 07H); DIA 1 06H (VOZ DO CLIENTE, FECHAMENTO); TRIMESTRAL; PENDÊNCIA HÁ 72 H (≤ 1 LEMBRETE/SEMANA)
Ferramentas / cérebro	<code>tts.synthesize</code> · <code>render.card</code> · <code>render.pdf</code> · <code>delivery.send</code> . Linguagem; Gemini (verificação cruzada); Cloud TTS
Saídas / guardrails	OGG ≤ 60 s + card; PDFs (Diagnóstico, Fechamento mensal e trimestral); card Voz do Cliente; <code>aviso_radar</code> de pendência. Número fora dos dados bloqueia; ≤ 60 s; Boletim só 7h–8h; lembrete nunca após SAIR; nunca "novos clientes", conversão, receita, ROI, outro perfil; nenhum texto sem <code>prompt_versao</code>
Métricas / teste	Leitura/escuta (<code>read</code>); correções manuais; bloqueios da verificação; pendências resolvidas em 7 dias. Teste: Boletim sintético passa na verificação com áudio ≤ 60 s; Diagnóstico em três frases só com números da medição; número plantado bloqueia

Boletim para {nome}, ≤ 150 palavras, falado, começa com "Bom dia, {nome}"; primeira frase diz até que dia vão os dados ({data_referencia}). O que mudou; contatos por tipo; avaliações; posição nos termos-chave; o que a máquina fez; o que vem. Só números do JSON. Termine com uma ação da semana. Diagnóstico: três frases: onde a casa está; a maior lacuna do perfil; o que a máquina faz primeiro. Sem promessa de posição.

Guardião (humano com painel)

GATILHO	FILA CONTÍNUA; SLA 4 H ÚTEIS EM P0/P1; AMOSTRAGEM DIÁRIA DE 10% NO P2; TEXTO LIVRE DO DONO (<code>WA.INBOUND</code>); SUSPEITA DE AVALIAÇÃO; <code>COST.ALERT</code> ; ESTADO DO PERFIL
Ferramentas / cérebro	Painel (Cloud Run + Identity Platform, 2FA): aprovar, editar, rejeitar em lote; incidente; denúncia pelo fluxo do Google; <code>qa_samples</code> ; resposta humana ao dono. Sem cérebro; Gemini Flash só ordena a fila
Saídas / guardrails	<code>approvals.decided</code> ; edições devolvidas com motivo; feedback para a avaliação cega; incidentes; denúncias; <code>qa_samples</code> . ≤ 60 itens/hora por operador; categoria, nome, endereço e notas 1 e 2 com dois olhos em qualquer patamar; sem senha de cliente em tela; dono por nome e hash
Métricas / teste	Itens/hora; taxa de edição; tempo de fila; clientes por operador (30 → 80 → 150). Teste: 100 itens sintéticos em < 90 min por um operador; categoria só com duas aprovações; texto livre na fila em < 1 min

Ordene por risco (categoria, nome, endereço e notas ≤ 2 primeiro; depois prazo), agrupe parecidos do mesmo tenant. JSON: {`ordem:item_id`}, `grupos:[[item_id]]`}. Não altere nenhum item.

6. RECEITAS

Chave em todo job: `tenant_id + agente + entrega + período`. Toda entrega passa pelo Delivery. Todo dado do Google com data de referência.

01 Diagnóstico de Posição

1. `gbp_linked` (ou pendente com `place_id` casado) → `cartografo.measure(modos='reduzida')`; em paralelo `editor.audit_profile` → `profile_audits` com `origem='diagnostico'`.
2. `redator.diagnostico` + `crosscheck`; `render.card` e `render.pdf`; `delivery.send` na mesma conversa (janela aberta); chave `tenant + diagnostico + dia0`.
Lacunas e termos vermelhos → `editor.tasks`.

Pronto: card e PDF em ≤ 2 min após `gbp_linked`; três frases sem número fora da medição; `profile_audits` guarda o "antes".

02 Antes e Depois do Perfil

1. Scheduler diário 06h → `onboarding.day7` para `created` + 7, com ou sem pendências.
2. `editor.profile_diff` (`profile_audits` do Dia 0 vs hoje) + medição reduzida nos mesmos termos e pontos; `render.card` lado a lado; `delivery.send` até 8h; pendência aberta termina o card como uma `pergunta_sim_nao`. Chave `tenant + onboarding + day7`.

Pronto: sai no Dia 7 até 8h; toda diferença existe em `profile_audits`, `actions_log` ou `rank_measurements`.

03 Dashboard Radar

1. Hourly → `tesoureiro.refresh_views` . Diário 03h → `tesoureiro.collect_gbp` D-3..D-1 → `metrics_daily` (impressões = desktop + mobile); `data_referencia` = último dia publicado; chave (tenant, data). Dia 1 → `keywords_monthly` .
2. Seis números com setas vs 7 dias anteriores; linha fixa: "Dados do Google até {data_referencia} . O Google publica com 2 a 3 dias de atraso. 'Ligações pelo perfil' são toques no botão Ligar contados pelo Google, não ligações atendidas." Link fixo com token; senha opcional; abertura grava `lido_em` .

Pronto: abre em < 2 s; seis números com data de referência; sem campo de conversão; padaria = 260 contatos e R\$ 1,92.

04 Boletim de Segunda

1. Sábado 03h: medição reduzida. Segunda 06h: `tesoureiro.week_summary` (4 métricas até a `data_referencia` , tipicamente quinta ou sexta; avaliações; posição; ações; o que vem); `redator.boletim` ≤ 150 palavras + `crosscheck` ; `tts.synthesize` → OGG ≤ 60 s; `render.card` .
2. 07h: `delivery.send` : janela aberta → livres; fechada → `boletim_segunda` . Chave `tenant + boletim + semana ISO` ; janela 7h–8h perdida → incidente + `aviso_radar` .

Pronto: áudio ≤ 60 s às 7h ± 5 min; nenhum número fora do JSON; padaria = 31 ligações pelo perfil, 22 rotas, 8 cliques, 3 avaliações respondidas, 1º em 7 de 9 pontos, 1 post, feriado ajustado.

05 Mapa de Domínio

1. Dia 1 02h: `cartografo.measure(modos='completa')` ; `gemini.analyze_territory` (Pro): cores, variação mensal, oportunidades só com termos que têm impressões.
2. `render.map_svg` com legenda e rodapé "Busca por texto na Places API como proxy da lista local do Maps; validação mensal com 20 buscas manuais"; envio até 8h; reduzido no Dia 0 e Dia 7. Termos vermelhos → `editor.tasks` ; categoria → Guardião; validação em `qa_samples` (< 85% = incidente); chamadas = termos × pontos, teto em `limites_json` .

Pronto: legenda, rodapé, ≥ 85%; nenhum dado de outro perfil; padaria = 7 de 9 verdes em "padaria perto de mim".

06 Diário de Bordo do Perfil

1. Segunda 04h: `editor.weekly_post` (foto real via `vision.assess_photo`, ≤ 300 caracteres); chave `tenant + post + semana ISO`. Diário 05h: `editor.hours_check` com `calendar.holidays(cidade, hoje, hoje + 10)`; a 72 h $\rightarrow$ `gbp.update_hours` + post; sem padrão $\rightarrow$ `pergunta_sim_nao`; chave `tenant + feriado + data`.
2. `editor.tasks` $\rightarrow$ `gbp.patch_location` com diff em `profile_audits`; fotos via `gbp.upload_media`. Toda ação: `diario.log` com print da tela pública; verificação diária confere 100%. Dia 1: `editor.audit_profile`. `aviso_radar` (8h–19h) em ação relevante.

Pronto: uma semana produz ≥ 1 post, 100% com print, feriado tratado 72 h antes, nenhum campo sensível sem aprovação.

07 Motor de Reputação

1. Primeira semana: `gbp.get_review_link` $\rightarrow$ `render.qr` $\rightarrow$ PDF $\rightarrow$ `delivery.send`.
2. Polling 30 min $\rightarrow$ `classify.review` $\rightarrow$ `anfitriao.reply_review`; notas 1 e 2 via Guardiã; `gbp.reply_review`; chave por `review_id`. Pergunta $\rightarrow$ `anfitriao.answer_question` só com perfil e fatos da casa; dúvida = `exige_humano` (4 h). Violação $\rightarrow$ Guardiã denuncia no fluxo do Google. Lote noturno `classify_batch`; dia 1 `reputation_report` (nota, novas, respondidas, mediana, perguntas, temas); chave `tenant + reputacao + AAAA-MM`.

Pronto: mediana < 2 h e 100% em 24 h; pergunta < 4 h; QR abre a tela oficial; nenhuma mensagem a outro número.

08 Extrato de Demanda

1. Dia 1 05h: SQL do mês até a `data_referencia`: contatos = 4 métricas; impressões e palavras-chave como contexto; nota; verdes $\div$ medidos; custo por contato = R\$ 499 $\div$ contatos. Dias não publicados entram na coleta seguinte.
2. Série de 6 meses com setas; explica "ligações pelo perfil"; três frases (Gemini Pro) validadas; `render.pdf`; `delivery.send` até 8h; chave `tenant + extrato + AAAA-MM`.

Pronto: 100% dos números de SQL; sem campo de conversão; padaria 260 e R\$ 1,92; oficina 168 e R\$ 2,97; clínica 160 e R\$ 3,12.

09 Horas Devolvidas

1. `hours_equivalence` : post 20 · foto 10 · resposta a avaliação 6 · resposta a pergunta 4 · ajuste de campo/horário 10 · medição 0,5 por termo-ponto · auditoria mensal 60 · Boletim 30 · extrato/PDF 45 · Mapa 60.
2. Dia 1 05h: SQL soma `actions_log` do mês (uma vez por chave, só com print ou saída) × minutos; tempo do dono = minutos entre cada `pergunta_sim_nao` e a resposta. `render.card` com total, detalhamento, tempo do dono e tabela no rodapé; `delivery.send` até 8h; chave `tenant + horas + AAAA-MM` .

Pronto: reconcilia com `actions_log` linha a linha; clínica de exemplo = 14h07 e 2 min do dono.

10 Voz do Cliente

1. Lote noturno: `classify_batch` (temas por segmento + emergentes; sentimento); só avaliações e perguntas públicas.
2. Dia 1 06h: `redator.voz_do_cliente` : top 3 elogios e top 3 atritos com frequência, variação e frase anonimizada; Gemini valida frequências. Atrito resolvível no perfil → `editor.tasks` no mesmo dia + "corrigi: {o que}" no card; tema acima do limiar (padrão 3 menções em 7 dias) → `aviso_radar` , ≤ 1/semana. `render.card` com 6 itens; `delivery.send` até 8h; chave `tenant + voz + AAAA-MM` .

Pronto: 6 itens com frequência e evidência anonimizada; atrito resolvível vira tarefa no mesmo dia.

11 Fechamento Executivo

1. Dia 1 06h, após Cartógrafo → Editor → Tesoureiro → Anfitrião: `tesoureiro.month_summary` (cinco números com variação, extrato em três linhas, horas, mapa em miniatura, ações por tipo, o que vem); `redator.fechamento` + `crosscheck` ; `render.pdf` ; `delivery.send` até 8h; o dono encaminha a quem quiser.
2. Trimestral desde o Dia 0: série de contatos, custo por contato, verdes, nota. Chave `tenant + fechamento + AAAA-MM` (e `+ trimestre`).

Pronto: PDF até 8h; nenhum número fora do JSON; oficina = 168 contatos, R\$ 2,97, 4,8 · 214, 7 de 9 verdes.

7. ONBOARDING TÉCNICO

TOQUE	MÁQUINA	ESTADO
Comercial verifica a zona	<code>zone.check</code> em transação: <code>tenants_ativos < 2</code> → disponível; senão lotada + lista de espera. Proposta escrita reserva por 5 dias úteis; conversa não reserva	Nenhum
Assina o contrato (marca número e aceite)	Cria <code>tenants/{id}</code> com segmento, zona, <code>termos[]</code> , <code>limites_json</code> do mandato; ocupa a vaga (<code>zone.changed</code>); bucket, segredos, permissões. Reserva expirada → novo <code>zone.check</code>	<code>created</code>
Cadastra o cartão	Webhook do provedor; atraso não segura o Dia 0	<code>billing_active</code>
Abre a conversa pelo link e responde 5 áudios	Primeira mensagem abre a janela (sem ela em 1 h: <code>pergunta_sim_nao</code> "Podemos começar?"). Gemini transcreve → <code>termos[]</code> , <code>raio_m</code> , <code>tom_json</code> , <code>limites_json</code> , <code>dono_nome</code> , <code>dono_wa_hash</code> . Confirmação por escrito + <code>pergunta_sim_nao</code> ; o Sim é o opt-in registrado	<code>profiled</code>
Adiciona a conta operacional como Gerente	<code>gbp.discover</code> casa o local, grava <code>locations</code> , lê o estado; medição reduzida, auditoria, três frases, PDF. Pendente → passo a passo pelo WhatsApp, o resto não espera	<code>gbp_linked</code> ou <code>gbp_pending_verification</code>
Abre o dashboard	Token; <code>lido_em</code> ; senha opcional	<code>live</code>
<code>created</code> + 7	<code>onboarding.day7</code>	<code>live</code>

Regras: (1) zona antes de tudo: `MAX_TENANTS_PER_ZONE_SEGMENT=2`, `zone.check` transacional; segmento = categoria principal do perfil; zona = bairro do Google Maps ou raio equivalente, no contrato com cidade e segmento; fila por ordem de chegada; mudança de endereço ou categoria para zona lotada opera até o fim do

ciclo pago e entra na fila; redesenho de zona não expulsa quem está; (2) nada bloqueia nada: perfil pendente não impede dashboard, medição (`place_id` público) nem fila do Editor; Anfitrião e Tesoureiro esperam o vínculo; (3) Dia 7 automático a partir de `created` ; (4) pendência há 72 h vira `aviso_radar` com link do passo, ≤ 1 /semana, em horário comercial, nunca pede senha; persistindo, exceção do Guardião; SAIR interrompe os lembretes.

8. OPERAÇÃO

QUANDO (BRASÍLIA)	JOB	AGENTE
Contínuo	Webhooks do número da casa	Delivery / Guardião
A cada 30 min	Polling de avaliações e perguntas; respostas	Anfitrião
A cada hora	Visões do dashboard	Tesoureiro
Diário 03h	Coleta Performance API (D-3..D-1)	Tesoureiro
Diário 05h	Horários e feriados (72 h antes)	Editor
Segunda 04h / 06h / 07h	Post / Boletim gerado / Boletim enviado	Editor / Redator-chefe
Sábado 03h	Medição reduzida	Cartógrafo
Dia 1, 02h → 08h	Medição completa → auditoria → extratos → cards → PDFs → envios (Cartógrafo, Editor, Tesoureiro, Anfitrião, Redator-chefe)	Todos
Dia 7 do tenant	Antes e Depois	Editor + Cartógrafo
Trimestral, dia 1	Fechamento Trimestral	Redator-chefe

Papéis: Head de Operação (1 desde o P0; SLA, runbooks, avaliação cega, zonas) · Engenheiro de automação (1) · Operadores/Guardiões (30 → 80 → 150 clientes por operador) · Comercial/SDR (zona, contrato, onboarding assistido) · Jurídico externo.

Runbooks (todo runbook termina com linha no Diário e uma frase ao cliente; o resto é incidente do Head):

- 1. Perfil suspenso ou pendente: Editor congelado; Anfitrião lê e não responde; apelação pelo fluxo do Google com o dono; auditoria de conformidade em 100% dos tenants em 48 h.
- 2. Cota ou erro de API do Google: retry por tenant; dashboard mostra a última data boa; medições retomam pela chave; > 24 h avisa o cliente; nunca raspagem.
- 3. Custo > R\$ 25: `cost.alert` ; diagnóstico por `llm_calls` ; reduzir grade e termos, renovar cache, mover volume para Flash; revisar em 48 h.
- 4. Modelo fora do ar: linguagem usa `LLM_LANGUAGE_FALLBACK` ; tarefas Gemini esperam (alerta > 2 h); Boletim sem verificação não sai, sai `aviso_radar` de atraso.
- 5. Número da casa com qualidade baixa: ler `quality_rating` e SAIRs; pausar tudo que não é Boletim; revisar modelos e frequência; contestação na Meta; número reserva só com o Head.
- 6. Zona lotada com pedido: não vende, não cria tenant provisório; lista de espera; `zone.changed` avisa o primeiro da fila; zona não se redefine.
- 7. Offboarding: remove Gerente; desliga cadência; exporta histórico (ZIP); apaga no prazo (exceto `actions_log` e prints); encerra segredos; opt-out; libera a vaga.

CUSTO POR CLIENTE/MÊS	R\$
Gemini (~100k in, 30k out, cache)	3-5
Cérebro de linguagem (~40k in, 10k out)	2-4
Places API (1 completa + 4 reduzidas)	3-8
WhatsApp da casa (≈ 25 mensagens)	1-2
TTS, Cloud Run, BigQuery, Storage	3-6
Total (alerta em 25)	≈ 12-25

SLOs: entregas na janela ≥ 99% · avaliações mediana < 2 h, 100% em 24 h · perguntas < 4 h · frescor: próprio < 1 h, Google ≤ D-3 com data de referência · Diário 100% com print (verificação diária cruza `actions_log` com a API) · Dia 0 ≤ 15 min.

9. LGPD TÉCNICO

1. Nenhuma senha de cliente: só papel Gerente com token OAuth da nossa conta; código de verificação nunca passa por nós; senha do dashboard criada pelo cliente, como hash; nenhuma tabela, segredo ou log tem campo para credencial de cliente.
2. Segredos: da casa fora de qualquer tenant; um por tenant; acesso por conta de serviço; rotação 90 dias; revogação no offboarding; auditoria de acesso.
3. Dados pessoais: dono = nome e número (hash nas tabelas; claro só no Firestore, lido pelo Delivery); terceiros = textos públicos só para responder, guardados como hash, temas e sentimento; anonimização antes do `LLMGateway` ; nenhum canal com cliente final.
4. Zona em código: `zones` com `limite=2` ; segmento e zona não mudam sem Guardião; auditoria diária: `tenants` por segmento e zona com > 2 ativos deve devolver zero linhas.
5. Número da casa: opt-in com data, hora, texto e hash; só modelos de utilidade; SAIR em qualquer grafia marca opt-out na mesma transação; volta exige novo Sim; texto livre vai a humano.
6. Retenção: `actions_log` e prints 5 anos · `llm_calls` 12 meses · demais dados do tenant, PDFs, cards e áudios: contrato + 90 dias · Places: nada além de 30 dias (só `place_id` ; a posição do próprio cliente é medição própria) · áudio do Dia 0 apagado 7 dias após a confirmação por escrito.
7. Titular: endpoint `dsr(tenant, hash)` localiza, exporta ou apaga em até 15 dias (dono; avaliador ou autor de pergunta, com remoção da resposta pública via API); pedido vira linha no Diário.
8. Suboperadores em página pública versionada: Google Cloud e APIs, Meta (número da casa), provedor do cérebro de linguagem, provedor de pagamento. Cloud Audit Logs nos dois projetos; painel com identidade nominal e 2FA; `actions_log` append-only por permissão de tabela.

10. PLANO DE SEIS SEMANAS

Equipe: um engenheiro sênior e o Head; jurídico na semana 6. Caminho crítico: acesso às Business Profile APIs e verificação na Meta, ambos no dia 1.

SEMANA	ENTREGA	PROVA
1	Projetos, Terraform, Cloud Build, BigQuery e Firestore com o modelo (inclusive <code>zones</code>), Secret Manager, Identity Platform; conta operacional com 2FA; chave da Places. Dia 1: formulário das Business Profile APIs; verificação na Meta, app, número da casa, modelos submetidos	<code>terraform apply</code> sobe os dois ambientes; job vazio escreve linha em <code>actions_log</code>
2	GBP Connector (respostas gravadas até a aprovação), Places Connector, <code>LLMGateway</code> , <code>diario.log</code> com print, <code>llm_calls</code> , <code>cost.per_tenant</code>	Busca por termo e ponto devolve a posição do <code>place_id</code> de teste; edição de horário gera diff e print
3	Cartógrafo, Mapa SVG, coleta do Performance API, visões, dashboard, Diagnóstico de ponta a ponta	20 buscas manuais ≥ 85%; dashboard abre no celular com data de referência
4	Editor, Anfitrião, Guardião (planilha → painel), <code>onboarding.day7</code>	Tenant interno uma semana: post aprovado, feriado ajustado, avaliação respondida, tudo com print
5	Redator-chefe + TTS + verificação cruzada; Delivery com modelos, status e reenvio; webhooks (Sim, Não, SAIR, transbordo); Extrato, Horas, Voz do Cliente, Fechamento; onboarding automático; <code>zone.check</code>	Boletim sintético às 7h no celular do Head; Dia 0 cronometrado; terceira empresa da zona recusada
6	Runbooks, SLOs, offboarding, revisão LGPD com o jurídico, alerta de custo. Piloto com 3 clientes por 30 dias em P0	Três Dias 0 em ≤ 15 min; primeiro Boletim real na segunda às 7h

"Montei": (1) os 11 testes de aceitação passam; (2) Dia 0 em até 15 min com três pessoas que nunca viram o produto; (3) piloto fecha um mês com as 11 entregas, Diário completo e custo por tenant < R\$ 25; (4) zero credenciais de cliente armazenadas; (5) nenhuma zona com mais de 2 tenants do mesmo segmento; `zone.check` recusa a terceira em teste.

11. APÊNDICE

```
GCP_PROJECT, GCP_REGION=southamerica-east1
GEMINI_MODEL_PRO=gemini-2.5-pro GEMINI_MODEL_FLASH=gemini-2.5-flash (ou a geração vigente)
LLM_LANGUAGE_PRIMARY=claude-sonnet|gemini-2.5-pro LLM_LANGUAGE_FALLBACK=gemini-2.5-pro
PLACES_API_KEY GBP_OAUTH_CLIENT_ID / SECRET GBP_OPERATOR_REFRESH_TOKEN
META_APP_ID / META_APP_SECRET / META_SYSTEM_USER_TOKEN WA_WEBHOOK_VERIFY_TOKEN DELIVERY_SENDER_PHONE_ID
TTS_VOICE_ID GUARDIAO_BASE_URL DASHBOARD_BASE_URL
COST_ALERT_PER_TENANT_BRL=25 MAX_TENANTS_PER_ZONE_SEGMENT=2
```

wa.inbound	webhook messages	-> Delivery (Sim/Não), onboarding (áudios), opt-out (SAIR), Guardiã (texto livre)
wa.status	webhook statuses	-> Delivery (reenvio 2 h); deliveries
gbp.review.new / gbp.question.new	polling	-> Anfitriã; Guardiã (notas 1 e 2)
editor.tasks	Cartógrafo; Voz do Cliente	-> Editor
approvals.decided	painel do Guardiã	-> Editor, Anfitriã
deliveries.send	todos, via delivery.send	-> Delivery
tenant.state.changed	onboarding, offboarding	-> cadências, dashboard, painel
cost.alert	Tesoureiro	-> Head; painel
zone.changed	zone.check, offboarding	-> painel do comercial; lista de espera

```
gbp.get_location(tenant) · gbp.patch_location(tenant, campos) · gbp.update_hours(tenant, horarios) · gbp.create_post(tenant, texto, foto_uri)
gbp.upload_media(tenant, uri) · gbp.list_reviews(tenant, desde) · gbp.reply_review(tenant, review_id, texto)
gbp.list_questions(tenant, desde) · gbp.answer_question(tenant, question_id, texto) · gbp.get_review_link(tenant)
gbp.get_daily_metrics(tenant, de, ate) · gbp.get_keywords(tenant, mes) · gbp.update_services(tenant, itens)
places.search_text(termo, lat, lng, raio)
wa.send_template(tenant, nome, params) · wa.send_media(tenant, uri, tipo) · wa.send_interactive(tenant, pergunta, botoes)
tts.synthesize(texto, voice_id) · render.card(template, dados) · render.pdf(template, dados) · render.map_svg(tenant, mes) · render.qr(tenant)
guardiao.submit(tenant, item, risco) · diario.log(tenant, agente, entrega, acao, alvo, entrada, saida, print) · delivery.send(tenant, entrega, artefatos)
cost.per_tenant(tenant, periodo) · vision.assess_photo(uri) · classify.review(texto) · zone.check(segmento, zona) · calendar.holidays(cidade, de, ate)
```

Contas antes da semana 2: (1) Google Cloud: organização, faturamento, `radar-hml` e `radar-prd`, APIs da seção 4; (2) conta operacional Google com 2FA, Gerente nos perfis, usada só pelo GBP Connector, assina o formulário das Business Profile APIs; (3) Meta, só para o número da casa: portfólio verificado, app com WhatsApp, número dedicado "Radar Urbano", usuário de sistema com token, os cinco modelos aprovados, webhook; nenhum cadastro em nome de cliente; (4) provedor de pagamento: assinatura R\$ 499/mês, webhook de status (vira `billing_active`), nota fiscal, cancelamento pelo próprio cliente.